

POS: 0.452 | 0.891

LATENCY: 12ms

¿Cómo funciona un Modelo de Lenguaje Grande (LLM)?

Anatomía de una predicción: De la estadística a la fluidez.



MEM: 64GB

> ESTADO DEL SISTEMA: INICIANDO ANÁLISIS... | V 1.0

LATENCY: 12ms

NODES: 10^9

MEM: 64GB

COORD: X-782.4 Y-289.2 | LATENCIA: 2.4ms



ADVERTENCIA DE SISTEMA

NO HAY PENSAMIENTO DETECTADO.

Un modelo de lenguaje no piensa, no sabe y no entiende. Lo único que hace es calcular qué fragmento de texto es más probable que venga después. Todo lo demás emerge de este mecanismo.

PROCESAMIENTO DE DATOS

COORD: X-782.4 Y-289.1
LATENCIA: 2.4ms



CAPAS OCULTAS: ACTIVAS
NODO 1428: RESPONDIENDO
ANOMALIA DETECTADA: 0.004%

TOKEN_STREAM: [0x4E2A, 0xB1F9, 0x7C3D] | ESTADO: LATENTE | MODO: CÁLCULO PROBABILÍSTICO |

FASE 1: ENTRADA DE DATOS

👤 HUMAN INTERFACE VIEW

¿Cuál es la capital de...?

💻 MACHINE INTERFACE VIEW

```
ASCII: ¿ C u á l   e s   l a   c a p i t a l   d e ...
HEX:   BF 43 75 61 6C 20 65 73 20 6C 61 20 63 61 70 69 74 61 6C 20 64 65 2E 2E 2E
BINARY: 10111111 01000011 01110101 01100001 01101100 01011 01001 01101001 01111001
        10111111 01000011 01110101 01100001 01101100 01011 01011 01101001 01111010
        10111111 01000011 01110101 01100001 01101100 01011 01021 01101001 01111010
        10111111 01000011 01110101 01100001 01101100 01011 01001 01101001 01111001
        10111111 01000011 01110001 01101101 ...
```

Para el modelo no hay preguntas, intención ni significado. Solo hay letras, espacios y signos. El significado es una proyección humana.

INTENT: NULL

CONTEXT: NULL

TOKENIZACIÓN



El texto se rompe en piezas. Un token puede ser una palabra, un prefijo o un espacio.

A partir de aquí, el modelo deja de ver texto. Solo ve números.


```
TOKEN_STREAM: [0x4E3A, 0x61FP, 0x7C3R]  
EETAP: PROCESAREO  
MSBO: CALEULO PRGBABLLSTIED
```

```
TOAEX_STREAM: [0x4E2A, 0x61F9, 0x7C2D]
```

```
it: 03 - 8.8759  
T: 382293
```

EMBEDDINGS (VECTORES)

Los números se convierten en coordenadas. Es una posición en un espacio matemático.



TOAIK_STREAM: [Bx1E2A, Bx817.9, Bx7E30]


CODIFICACIÓN POSICIONAL

El modelo añade información de posición a cada token. Sin esto, no podría distinguir entre sujeto y objeto.




LA VENTANA DE CONTEXTO

Un espacio de trabajo limitado. El modelo no 'recuerda' la conversación entera, solo lo que cabe aquí. Cuando algo queda fuera de la ventana, para el modelo deja de existir.



EL NÚCLEO: TRANSFORMER

El modelo procesa todo el texto a la vez, capa tras capa. En cada capa ocurren dos pasos: Atención y Transformación.



Mecanismo de Auto-Atención

El sistema decide qué importa. No razona, **solo pondera influencias.**

La capital de España es...

Peso Alto: Contexto Relevante

Transformación (MLP)

Una red neuronal toma la información seleccionada y ajusta los números para que el patrón 'suene bien'.



CHECKING FACTS: DISABLED.
SEEKING COMERENCE: ACTIVE.

Generación de Probabilidades

El modelo no entrega una respuesta única. Genera una puntuación para **cada palabra posible en el vocabulario**. El modelo elige lo **más probable**, no lo más **verdadero**.



Colapso de la Función

Se elige un token, no una idea completa. Según la configuración (temperatura), puede elegir siempre el más probable o introducir variación.



Generación Autoregresiva

El token elegido se añade al texto y todo vuelve a empezar. 1. Se añade al contexto. 2. Condiciona el siguiente paso. 3. Repetir hasta terminar.



Por qué falla el modelo

Las alucinaciones no son errores accidentales, son **consecuencias directas del diseño**.



Probabilidad $\neq$ Verdad.

Prioriza la fluidez sobre los hechos.



Compresión con Pérdida.

La información original no está exacta.



Alucinaciones.

Si no está en el patrón, el sistema inventa para llenar el hueco.

Conclusión Operativa

Un LLM es un motor probabilístico, no una fuente de verdad.

Entender su mecánica es el primer paso para usarlo con criterio, no con fe.

[FIN DEL PROCESO]