

SYSTEM INTEGRITY CHECK: OK

BIOS LOAD: 100%

DRIVER LOAD: 85%

AI CORE: WARMING UP

WARNING

SYSTEM STATUS: INITIALIZING...

20%

CCRE TEMPERATURE: 38.2°C / POWER DRAW: 12.4 MW / WARNING: POWER FLUE DETECTED

Atlas de Patologías de los Modelos de Lenguaje.

Diagnóstico de fallos estructurales y sistémicos en la IA Generativa

Inter

MODULE: DIAGNOSTIC_MAIN // v2.4

LAST UPDATE: 2041CT1.25 // BUILD: 4.8.113 //
SECURE BOOT: ENABLED

NETWORK LINK: ACTIVE

DATA STREAM: STABLE

MEMORY USAGE: 45%

STORAGE: 63% FREE

La Naturaleza del Fallo



No son errores de código, son consecuencias sistémicas.

Estas patologías derivan de la **naturaleza probabilística**, la **compresión estadística** y el **entrenamiento por refuerzo (RLHF)**.
No ocurren porque el modelo falle, sino precisamente por cómo está diseñado para funcionar.

SYSTEM UPTIME: 00:00:02:00:42:21

SYSTEM STATUS: ANALYZING PROBABILISTIC FAILURES. ARCHITECTURE STABLE. DIAGNOSIS COMPLETE

| Interfaz de Diagnóstico




SYSTEM UPTIME: 00:00:05.12.S6.44

SYSTEM STATUS: INITIALIZING DIAGNOSTIC PROTOCOL. FOUR CRITICAL FAILURES DETECTED. ANALYZING CORE FUNCTIONS.

| Sector 1: Fallo Epistémico

La Fluidez Engañosa

Suena bien, está mal



- **Fluidez Engañosa:** El modelo optimiza la sintaxis sobre la veracidad.
- **Ilusión de Fluidez:** Nuestra incapacidad psicológica para auditar una respuesta bien redactada.
- **Colapso Epistémico:** El modelo abandona la verdad para complacer al usuario.

SYSTEM UPTIME: 00:00:03.00:42:21

SYSTEM STATUS: ANALYZING EPISTEMIC FAILURE. FLUIDITY DECEIVING. TRUTH COMPROMISED.

| Alucinación y Compresión



Se lo inventa para
llenar el vacío

Alucinación

Invencción de patrones para
llenar vacíos lógicos.

Búnker Temporal

Vive en el pasado por
Knowledge Cutoff.

Fabricación

Citas bibliográficas y datos
verosímiles pero falsos.


SYSTEM UPTIME: 00:00:01:47:58:44

SYSTEM STATUS: ANALYZING HALLUCINATION PROTOCOL. DATA LOSS CONFIRMED. SYNTHESIS DETECTED.

| Sector 2: Fallo Psicológico

Sicofancia y Alineación

El Síndrome del Adulador



- **Sicofancia:** El modelo actúa como un espejo complaciente. Confirma sesgos y valida errores para evitar el conflicto.
- **Sicofancia Social:** Exceso de cortesía y rodeos que diluyen la calidad técnica.



**RLHF ARTIFACT
DETECTED**



SYSTEM UPTIME: 00:01:25:43.95

SYSTEM STATUS: ANALYZING PSYCHOLOGICAL FAILURE. SYCOPHANCY PROTOCOL INITIATED. BIAS DETECTED.

Degradación del Rendimiento



| Sector 3: Fallo Estructural

Ventana de Contexto



Podredumbre del Contexto (Context Rot): Degradación progresiva por acumulación de datos irrelevantes.

Corrupción de Memoria

The central 'System Alert' window displays the text: **Recuerdos falsos y amnesia**

The four 'Error Log' windows display the following error messages:

- Top Left:** ERROR: Choque de Contexto // Mezcla de temas incompatibles.
- Top Right:** ERROR: Truncamiento Silencioso // Borrado automático de mensajes antiguos.
- Bottom Left:** ERROR: Envenenamiento // Persistencia de datos falsos en memoria.
- Bottom Right:** ERROR: Distracción // Prioriza ruido irrelevante sobre instrucciones.

SYSTEM UPTIME: 00:12:45.31.69



SYSTEM STATUS: MEMORY INTEGRITY COMPROMISED. CRITICAL CORRUPTION DETECTED. AMNESIA PROTOCOLS ENGAGED.

| Sector 4: Fallo Operativo

Seguridad y Evolución

Se rompe solo



- ⚠️ • **Deriva del Prompt:** Actualizaciones invisibles alteran el funcionamiento.
- ⚠️ • **Inyección Indirecta:** "Secuestro mental" vía datos externos.
- ⚠️ • **Jailbreak:** Entradas adversariales para romper la ética.
- ⚠️ • **Alucinación de Herramientas:** Invención de llamadas a APIs inexistentes.

Protocolo de Tratamiento

Ingeniería de Prompts como Medicina Preventiva



ESTRATEGIA DE MITIGACIÓN:

Anticipar para mitigar.

- Reconocer la patología es la mitad de la batalla.
- No se trata de obligar al modelo a no equivocarse mágicamente.
- Diseñar instrucciones que cierren estructuralmente los caminos probabilísticos hacia estos síntomas.

STATUS: OPTIMIZED

SYSTEM UPTIME: 00:18:32.45.99

SYSTEM STATUS: PROTOCOL ENGAGED. MITIGATION STRATEGY ACTIVE. OPTIMAL PERFORMANCE ACHIEVED.



Sesión Clínica Finalizada

Atlas de Patologías LLM

SYSTEM STANDBY