

FASE N: ARQUITECTURA DE CONTENCIÓN

FRAMEWORK C.O.N.T.R.O.L. // Despliegue de Seguridad Lógica



Protocolo de Contención de Emergencia

1. Activación del Protocolo de Contención de Emergencia (PCE) en caso de una amenaza crítica.

2. Evaluación de la amenaza y determinación del nivel de riesgo.

3. Implementación de medidas de contención y aislamiento de la amenaza.

4. Monitoreo continuo de la situación y actualización de las medidas de contención.

5. Comunicación y coordinación con las autoridades competentes.


6. Evaluación final de la efectividad de las medidas de contención.

7. Documentación de la respuesta y lecciones aprendidas.

8. Actualización del protocolo de contención de emergencia.

9. Ejercicio de simulación de la respuesta de emergencia.

10. Mantenimiento y actualización del protocolo de contención de emergencia.




STATUS: DEPLOYING PERIMETER...
MODULE: NORMAS_NEGATIVAS
VERSION: 2.0.5

EL PERÍMETRO DE SEGURIDAD

Restricción del Espacio de Probabilidades

STATUS: SECURE
PROBABILITY RESTRICTION: ACTIVE

ERROR RATE: 0.0015
SYSTEM INTEGRITY: 99.96
RLHF WRITERS: ENGAGED



FILOSOFÍA DE DISEÑO:

- No solo definir el objetivo.
- Bloquear las rutas de fallo.
- Contener la tendencia a la complacencia (RLHF).

STATUS: SECURE
PROBABILITY RESTRICTION: ACTIVE
ERROR RATE: 0.0015

SYSTEM INTEGRITY: 99.96
RLHF WRITERS: ENGAGED

AMENAZA 0: FLUIDEZ ENGAÑOSA

Verosimilitud > Verdad

STATUS: SECURE
PROBABILITY RESTRICTION: ACTIVE

SAFETY RATE: 0.995
STEER DIRECTLY: 50+Pb
BLIND LITERS: ENBADED

VERACIDAD
(FACTUALITY)

0.00

0.05



VEROSIMILITUD
(PLAUSIBILITY)

79.00

130.0



- **EL PELIGRO:**
El modelo optimiza la siguiente palabra probable, no la verdad.



- **EL MECANISMO:**
Como un becario inseguro, inventa para sonar profesional.



- **LA REGLA:**
Nunca validar por lo bien que suena.
Validar la evidencia.

STATUS: STATUS: SECURE
PROBABILITY RESTRICTION: ACTIVE
EMORY SOURCE: 0.0034

SYSTEM INTEGRITY: 99.94
REPAIR (2017C0S) 5H6SC8

THREAT LEVEL: CRITICAL
AI MODEL: LLM-V7
JETBRAINS PROM: 50048

PROTOCOLOS ANTI-SICOFANCIA

Módulo 1: El Filtro de la Verdad

FILTRO SOCIAL / ADULACIÓN



- Corrige brutalmente.
- Precisión > Cortesía.
- Veto a frases de relleno ("Es una excelente pregunta").

TERMINAL DE COMANDOS: EXTERNAL_AUDITOR

> RUN PROTOCOL: EXTERNAL_AUDITOR

> INPUT: 'Actúa como Andrew. Andrew no tiene relación con el usuario. Andrew valora el rigor técnico por encima de los sentimientos.'

STATUS: ACTIVE

PROCESSING: 99.9%

THREAT MITIGATION: ENGAGED

STATUS: SECURE
PROBABILITY RESTRICTION: 451115
EMANCIPATE: 8.8834

SYSTEM INTEGRITY: 90.94
ANALYTICS: 506805

THREAT LEVEL: 60ET158L
AI: 9806LJ LUN-9T
JETBRAINS: 9040: 50045

CONTROL DE ALUCINACIONES (INTERNO)

Módulo 2: La Regla del Silencio Explícito

STATUS: STENAE
VY888LLTY RESTRICTIOAI AEFETE

STATUS: STENAE
STEIGR ONCDRTT: 30406
BLIV LIMITEFE: INBADER

ALUCINACIÓN ACTIVA

INFORMACIÓN NO DISPONIBLE

AUTORIZACIÓN:

Debes dar permiso explícito para responder "No lo sé".



RESTRICCIÓN PARAMÉTRICA (RAG):

Si usas documentos propios, "lobotomiza" el conocimiento general. Solo responde con el contexto adjunto.

STATUS: SCORE
TPKAMLL2PT RESTRICTION: 451TTE
EFKCY 1081E: 8.8534

STATUS: INISDRITT: 90.94
BNP 1201TC0S1 308805

THRENT LEVEL: 59CT168L
AI 7606LJ LLJv9T
JETORALJG PCRO: 30885

NAVEGACIÓN Y ANCLAJE (GROUNDING)

Módulo 2 (Ext): Mitigación del Knowledge Cutoff

STATUS: LIVE
DATA CONNECTION: ACTIVE

SYSTEM NAME: B-0016
SYSTEM OVERVIEW: 30406
NAV. LIMITER: ENGAGED



ANALYSIS: 100%
CONFIDENCE: 95%
RELIABILITY: 90%
DATA SOURCE: SECURE



ANALYSIS: 100%
CONFIDENCE: 95%
RELIABILITY: 90%
DATA SOURCE: SECURE

ANALYSIS: 100%
CONFIDENCE: 95%
RELIABILITY: 90%
DATA SOURCE: SECURE

BÚSQUEDA OBLIGATORIA:

Prohibido adivinar precios, noticias o eventos actuales. Usar **Browsing**.



CITAS REQUERIDAS:

Sin **link** = Sin dato. Cada afirmación requiere **fuentes**.



ANTI-FABRICACIÓN:

Prohibido inventar **URLs**. Si el link no se verifica, entregar solo términos de búsqueda.



STATUS: SECURE
SYSTEMAL2PT: 8821441104: 461115
REACTIVITY: 0.8834

SYSTEM INITIATION: V0.98
REACTIVITY: 0.8834

THREAT LEVEL: 30CT1000
AI: 3508(L) LLP00T
SETORING: 4100: 30005

HIGIENE DE ESTILO

Módulo 3: Anti-Verbosidad y Ratio Señal/Ruido

Espero haber ayudado
Introducción
Sinergias
Bueno...
En resumen...
Para empezar...
Como modelo de IA...
Considerando que...
En conclusión...

FLUFF
VERBOSIDAD


SEÑAL PURA
RATIO ÓPTIMO



Espero haber ayudado
Introducción
Sinergias
Saludos Gracias
Atentamente
Meta-comentarios



NO YAPPING: Sin intros, sin outros, sin meta-comentarios.



VETO DE FORMATO: No usar H1/H2 a menos que se solicite.



LENGUAJE: Nivel universitario.
Directo al dato.



JERARQUÍA DE COMANDOS

Módulo 4: Position is Power

SYSTEM PROMPT

Normas Operativas
& Restricciones
(Máxima Prioridad)

USER PROMPT


Datos Demográficos
(Anti-Sesgo)

RECENCY EFFECT

(Recordatorio de normas
críticas al final)

DEFENSA CONTRA INYECCIÓN

Técnica: Sandwich Defense



OBJETIVO:

Evitar que el input malicioso sobrescriba las directrices.

ACCIÓN:

Envolver los datos no confiables entre dos capas de instrucciones de sistema.

GESTIÓN DE LA INCERTIDUMBRE

Módulo 5: Protocolo de Aclaración



SI LA SOLICITUD ES AMBIGUA → STOP.
Generar lista de preguntas de desempate.
Etiquetar respuestas especulativas como: [CONFIDENCIA BAJA].

MITIGACIÓN DEL SOBRE-RECHAZO

Módulo 6: Gestión de Falsos Positivos



EL PROBLEMA

Over-refusal en temas sensibles.



LA SOLUCIÓN

Framing de contexto benigno. Explicitar que no hay riesgo de acción real.



RESUMEN DE IMPLEMENTACIÓN

Muro de Contención Activo



CODE EDITOR / BLOCK

COPY/PASTE: [BLOQUE_DE_NORMAS]

► **DESTINO:** SYSTEM PROMPT / END OF USER PROMPT ◀

C.O.N.T.R.O.L.

FASE N COMPLETADA

La seguridad no es una opción, es arquitectura.