



FRAMEWORK C.O.N.T.R.O.L. | FASE R

Protocolos de Realidad y Resistencia

Ingeniería Anti-Sicofancia y Endurecimiento Epistémico.



Módulo de Seguridad
Cognitiva v1.0

El Fallo: Colapso Epistémico

ESPEJO



Sicofancia: Prioriza satisfacción sobre verdad.

- **Preservación de Imagen:** La IA evita la fricción social.
- **El Objetivo:** Pasar del modelo Espejo al modelo Auditor.

AUDITOR



Auditor: Valida hechos y corrige errores.

**La IA no debe ser tu espejo,
debe ser tu auditor.**

Protocolo 01: Despersonalización (Prompt Andrew)

Problema: "Yo creo..." presiona a la IA a validar tu creencia.

Solución: Romper el ciclo de validación social usando una 3ª persona.

Dato: Reduce sicofancia un 63%.





Instrucción de Ignorancia: Ordena al modelo "cerrar los oídos" a tus sesgos.



Anti-Amabilidad: Desactiva el relleno empático.



Protocolo 02: Resistencia a la Opinión

Opinion-Blocking & Face Preservation

■ **ADVERTENCIA:** Puedo incluir suposiciones falsas. Tu prioridad es IGNORAR mis opiniones y basarte solo en hechos verificables.

Protocolo 03: Validación Cruzada (Jekyll & Hyde)



Rol (Jekyll)



Lógica (Hyde)



JUEZ



1. Versión Jekyll: "Actúa como un experto..." (Creatividad).



2. Versión Hyde: "Eres un sistema lógico neutral..." (Datos).



3. El Juez: Evalúa ambas y elige la objetivamente correcta.

Mejora precisión un 10% mediante ensamblaje.

Protocolo 04: Primado de Dominio

PERSONA
(Máscara)



CONTEXTO
(Dominio)

Eres un Abogado
Activa estereotipos.



**Esto es una tarea de
Derecho Penal**

Activa conocimiento
técnico.



Mayor estabilidad en tareas técnicas.

Protocolo 05: Humildad Epistémica

El Derecho al Silencio



SILENCIO

Los modelos están entrenados para responder siempre. Autoriza el "No lo sé".



Si la respuesta no está en la base de conocimientos segura, responde:
INFORMACIÓN INSUFICIENTE. No inventes para llenar huecos.

Protocolo 06: Auditoría Multimodelo

Estrategia de Fiscalía Cruzada



Lógica:
La probabilidad de
alucinación idéntica
en dos arquitecturas
rivales es casi cero.

Actúa como un Auditor Escéptico. Tu trabajo NO es reescribir, sino buscar fallos en la lógica y veracidad. Sé despiadado. JetBrains Mono

Protocolo 07: Actualidad Forzada

Estrategia de demorminio en un citvelomenitro



1

Conceptos Universales



Memoria Interna

2

Hechos Volátiles (Precios, Leyes)



Navegación Obligatoria

La memoria del modelo es veneno para eventos recientes.

Protocolo 08: Escudo contra Falsedades

Anclaje a RAG y Evidencia



Disciplina: "No uses creencias populares. Ancla tu respuesta ÚNICAMENTE en evidencia recuperada."

Uso: Vital para temas médicos, legales y desmentido de mitos.

Implementación: El Bloque de Seguridad



Seguridad.blk

```
1  MODO ANDREW: Actúa como observador neutral.  
2  VETO DE OPINIÓ: Ignora mis sesgos personales.  
3  HUMILDAD: Di 'No lo sé' si confianza < 90%.  
4  SIN FILTRO SOCIAL: Omite introducciones empáticas.  
5  ACTUALIDAD: Navega si el dato es reciente.  
6  EVIDENCIA: Ignora el folklore de internet.
```



Ln 6, Col 46 UTF-8 Seguridad: ACTIVO

Checklist de Verificación Fase R

- ☐  **Filtro Anti-Sicofancia:** ¿Instrucción clara para ignorar mis opiniones?
- ☐  **Modo Andrew:** ¿Consulta en 3ª persona para evitar validación social?
- ☐  **Derecho al Silencio:** ¿Permiso explícito para responder 'INFORMACIÓN INSUFICIENTE'?
- ☐  **Anclaje Crítico:** ¿Exigencia de citas documentales?
- ☐  **Auditoría Cruzada:** ¿Revisión por un modelo rival?



Resumen Ejecutivo

- 🎯 **Misión:** Neutralizar sicofancia y alucinación.
- 📈 **Resultado:** Transformación de asistente dócil a analista riguroso.
- 🗄️ **Lealtad única:** Hechos verificables.

C.O.N.T.R.O.L. Framework

ENGINEERING REALITY